

Recursive Self-improvement 探索

具体方向划分


路线	核心问题	典型对象	优点	难点
1. Self-play / zero-data self-improvement	模型能否自己生成任务、自己解决任务、自己构造反馈，并训练自己？	model-centric reasoning system	概念最接近“自我进化”，闭环干净，少依赖外部数据	信息来源主要是模型自身，容易变成已有能力重组；对 base model 有效，但对 instruct/agent 边际收益可能小
2. Experience-driven evolving	agent 能否从真实任务成功/失败轨迹中提炼经验，并用于未来任务？	deployed agent / model+harness	最贴近真实 agent；有真实外部反馈；成本相对可控	容易退化成 memory augmentation；需要证明经验变成了可迁移能力，而不是简单检索复用
3. Auto-research / engineering optimization	agent 能否优化训练、后训练、数据、workflow、scaffold 或 harness？	research/engineering agent	目标明确、反馈可执行，长期潜力最大	工程和算力成本高；容易被认为是 AutoML/系统工程；要解决 overfitting、baseline、transfer

代表工作


Self-play

不依赖人工题库和标注，让模型自己出题、自己解题，在对抗中提高模型能力。


- Absolute Zero: Reinforced Self-play Reasoning with Zero Data (NIPS 2025 spotlight, 203 citations)




- R-Zero: Self-Evolving Reasoning LLM from Zero Data (ICLR 2026, 101 citations)



- SPIRAL: Self-Play on Zero-Sum Games Incentivizes Reasoning via Multi-Agent Multi-Turn Reinforcement Learning (ICLR 2026, 54 citations)



- Agent0: Unleashing Self-Evolving Agents from Zero Data via Tool-Integrated Reasoning (RSI@ICLR26, Outstanding, 34 citations)




- 优势：设定干净，容易上手
- 劣势：
 - 单纯依靠模型内部信息，缺乏外部反馈，这种学习范式可能存在问题。
 - 比如最关键的，模型自己出题的ground truth如何确定？Agent0采用的是majority voting里面得票最多的答案。其实很容易陷入只是在做概率分布的锐化。
 - 这种evolve的step通常也比较有限

Base Model	Method	AIME'24	AIME'25	AMC'23	HMMT	B-AIME	Brumo	GPQA	LCB	Avg
Qwen3-4B Instruct-2507	Untrained	58.8	44.0	87.5	30.0	32.0	56.5	52.5	32.6	49.2
	R-Zero	55.0	43.3	87.5	26.5	27.0	55.2	54.0	33.5	47.8
	DAPO	50.0	44.8	92.5	19.8	22.2	47.1	56.1	33.5	45.8
	RLVE	57.1	44.3	92.5	27.7	32.8	57.9	57.1	32.6	50.3
	EvoEnv	61.9	52.5	95.0	30.0	33.6	61.2	55.0	35.5	53.1
Qwen3-4B Thinking-2507	Untrained	86.7	78.8	97.5	56.9	53.1	81.9	65.2	59.0	72.4
	R-Zero	84.2	80.6	97.5	53.5	52.9	79.6	67.2	59.0	71.8
	DAPO	74.0	65.4	97.5	48.8	45.8	68.3	64.6	54.0	64.8
	RLVE	81.9	75.0	95.0	51.5	49.6	75.8	67.7	57.3	69.2
	EvoEnv	86.2	83.0	100.0	60.0	53.6	81.9	70.2	63.2	74.8
Nemotron Cascade-8B	Untrained	83.3	71.3	92.5	61.5	55.8	73.8	65.2	64.3	71.0
	R-Zero	83.3	71.5	97.5	55.8	50.1	73.3	58.1	62.1	69.0
	DAPO	78.3	63.5	100.0	40.0	40.6	65.8	61.6	60.6	63.8
	RLVE	79.8	69.4	100.0	55.4	54.3	74.2	66.2	56.6	69.5
	EvoEnv	84.8	72.3	100.0	64.2	57.2	78.8	65.7	62.8	73.2


Experience-driven evolving

agent 不再把每个任务当成一次性 episode，而是从连续任务流中的成功、失败、工具反馈、环境反馈和执行轨迹中提炼经验，并把这些经验沉淀为 memory、skill、workflow、verifier 或训练信号，使未来任务表现持续改善。


- ReasoningBank: Scaling Agent Self-Evolving with Reasoning Memory (ICLR 2026, 125 citations)



- SkilIOS: Learning Skill Curation for Self-Evolving Agents (Arxiv 7 May 2026)



- AgentEvolver: Towards Efficient Self-Evolving Agent System (Arxiv 13 Nov 2025, Tongyi Lab, 37 citations)



AgentEvolver 通过三个协同机制（自主生成任务、经验复用导航、单步差异化奖励）构建了一个自进化 RL 框架，让 LLM 智能体能够在减少人工干预的情况下自主驱动学习过程——Self-Questioning 解决任务稀缺、Self-Navigating 提升探索效率、Self-Attributing 改善样本利用率，三者叠加在长时域任务上取得了超越传统 RL 基线的显著效果，并配套了完整的上下文管理和环境服务基础设施以支持实际部署。

- Evolving-RL: End-to-End Optimization of Experience-Driven Self-Evolving Capability within Agents (Arxiv 11 May 2026, Xiaohongshu & PKU)

Evolving-RL 的核心洞察是：**经验提取质量与经验利用能力是相互依存的**，割裂优化会导致两者均陷入局部最优——噪声技能让 Solver 学会忽略经验，而低质量 Solver 反馈又无法有效监督 Extractor。为此，论文让 Extractor 和 Solver 共享参数，以技能在多个下游任务上的迁移表现作为统一监督信号，实现端到端协同进化，并通过规则过滤和负熵正则化保障训练稳定性，最终在 ALFWorld 和 Mind2Web 上大幅超越所有基线，同时验证了所提取技能的跨策略可迁移性。

- **优势：**这种范式更符合我们对自进化的预期，模型在自主探索和执行任务的过程中，积累经验，提高自己，有充分的外部反馈，也有充分的自主性
- **劣势：**
 - 在模型context能力不够完美的阶段，核心挑战还是memory的管理和利用。容易做成agent memory的优化，和self-evolving结合不紧密。（其实也不太算劣势）
 - 目前的自主化程度还是不够高，更多是人设定好探索的task，让模型自主积累经验。

Auto-research

让 agent 像研究员/工程师一样，在明确目标、可执行环境和有限预算下，自动提出假设、修改代码/数据/训练流程、运行实验、分析结果，并迭代优化一个研究或工程系统。

- <https://github.com/karpathy/autoresearch> (82.4k stars)
给 agent 一个小型 LLM training setup，有明确的指标。让 agent 修改 `train.py`，训练固定时间，检查 validation bits-per-byte，改进就保留，否则回滚。
- PostTrainBench: Can LLM Agents Automate LLM Post-Training? (RSI@ICLR26, Oral, 6 citations)
给 agent 一个 base LLM、目标 benchmark、一张 H100、10 小时预算，让 agent 从头搭建、自主优化 post-training：上网找数据、写训练脚本、运行实验、调整方法，最终提升 base model 在目标 benchmark 上的表现。agent 不被提供预设策略，需要自己上网、实验、curate data。
- InferenceBench: A Benchmark for Open-Ended LLM Inference Optimization by AI Agents
- MLS-Bench: A Holistic and Rigorous Assessment of AI Systems on Building Better AI (Arxiv 9 May 2026)
MLS-Bench 是一个评估 AI systems 是否能“发明更好的 AI 方法”的 benchmark。它发现当前 agents 更像工程调参助手，而不是可靠的 ML 方法发明者；真正瓶颈在于科学洞察、实验规划、泛化验证和 scaling claim，而不是单纯缺少搜索、算力或上下文。

-



优势：

- 任务设定很干净，目标明确
- promising。如果agent能够优化现在模型的pretraining、post-training、inference，效果的提升、收益的范围可能远超前两者

劣势：

- 成本极高：PostTrainBench中report

Cost Analysis We break down costs into API costs and GPU costs to help practitioners plan evaluations.

- *API costs.* Model choice dominates the API costs. Qwen3 Max is the most expensive at ~\$910 per run. Claude Opus 4.6 (Claude Code) costs ~\$600-750, and Claude Opus 4.5 (Claude Code) ~\$420. Gemini 3/3.1 Pro (OpenCode) costs \$225-310, Claude Opus 4.5 (OpenCode) ~\$250, and GLM-5 (Z.AI) ~\$170. Claude Sonnet 4.5 costs ~\$85. GPT-5.1 Codex Max (OpenCode), Kimi K2/K2.5, and GPT-5.1/5.2 (Codex CLI) all cost under \$35.
 - *GPU costs.* Assuming \$2.5-3/hour per hour for an Nvidia H100 (RunPod, 2026), each model-benchmark pair costs up to ~\$30. The full 4x7 matrix totals up to ~\$840.
- 如果做training side优化，不应该从头搭建数据、pipeline，而是完全匹配和大厂一致的基建。所以现在的核心工作，都是在为agent搭建pipeline，让它能跑通整个流程。
 - 正如MLS-Bench report，现有的优化可能更像是大号的超参数调优，都是工程层面的优化
 - 能做的可能是inference侧的自动化：LLMs Improving LLMs: Agentic Discovery for Test-Time Scaling

目标Benchmark

其实self-evolving这个领域，没有独有的task，不管是self-play还是experience-driven还是auto research，目标都是提高现有模型/agent在leading benchmark上的performance，比如AIME25、SWE-Bench等

Researchers & Labs

(以高年级PhD为主)

- **Peng Xia** (UNC Chapel Hill)

My research focuses on scaling **agents** through mid/post-training and data scaling. I focus on building (M)LLM agents equipped with **complex tool interaction** and **long-term memory**, ultimately striving towards autonomous self-evolving systems.

- SimpleMem: Efficient Lifelong Memory for LLM Agents
- Agent0-VL: Exploring Self-Evolving Agent for Tool-Integrated Vision-Language Reasoning
- ClawArena: Benchmarking AI Agents in Evolving Information Environments
- OmniMem: Autoresearch-Guided Discovery of Lifelong Multimodal Agent Memory
- MetaClaw: Just Talk--An Agent That Meta-Learns and Evolves in the Wild
- SkillRL: Evolving Agents via Recursive Skill-Augmented Reinforcement Learning
- Agent0: Unleashing Self-Evolving Agents from Zero Data via Tool-Integrated Reasoning

- **Siru Ouyang** (UIUC)

- SkillOS: Learning Skill Curation for Self-Evolving Agents
- ReasoningBank: Scaling Agent Self-Evolving with Reasoning Memory

- Ben Rank (Max Planck Institute)

My research focuses on risks from automated AI research.

- Yucheng Shi (Tencent AI Lab & University of Georgia)
- **Chengsong Huang** (Washington University in St. Louis)
- **Andrew Zhao** (Tsinghua University)

想法和探索

Idea

- 从 experience-driven self-evolving agents 出发，研究 agent 在任务中产生的经验，是否只能作为外部 memory 被检索复用，还是可以被选择性地内化进模型参数，成为更稳定的行为能力。
 - 怎么评估经验提炼的好？
- agent 在任务中产生的某些**高价值经验**，是否可以从外部 memory 升级为参数化能力，使模型在不依赖检索的情况下也能稳定受益？

为什么一定要内化？放在 **memory** 不可以吗？

- Memory 更适合存储具体、易变、低频、任务特定的信息，比如某个 repo 的结构、某个 API 的用法、某次具体失败的记录。这些东西放进参数没有必要，甚至有风险。
- 但有些 experience 不是具体知识，而是反复出现的、跨任务有效的行为模式。有价值的experience学进参数，也许能提高模型的整体intelligence

分析 or 方法？

提出一个 selective internalization framework：自动判断哪些 experience 应该留在 memory，哪些应该被蒸馏进参数，并用轻量训练方式完成内化。

实验

- 目前正在复现reasoning bank