

Experience-Driven Self-Evolving Agents: 领域发展梳理

个人 reading notes, 截至 2026 年 5 月
覆盖 2025/08 – 2026/05 的代表性工作

一、Context: 这个方向在大图景里的位置

在 recursive self-improvement 的大方向下, 目前主要有三条技术路线:

1. **Zero-data self-play**: 通过 self-play / synthetic interaction 自我提升
2. **Experience-driven self-evolving**: 通过执行任务、积累经验、反思迭代来自我提升
3. **Auto research**: 让 agent 自动做研究/训练实验, 加速 AI R&D 本身

本文聚焦第二条路线。这条路线的核心假设是:

当前 agent 执行任务都是一次性的, 没有形成可复用的 experience。如果让 agent 反思自己的交互历史并沉淀经验, agent 就能持续改进。

二、起点 (2025/08 – 2026/01) : Non-parametric memory 路线

代表工作: MUSE (Learning on the Job), MemRL

时间上恰好对应 Claude skill 概念刚火起来的时间窗口。

共同特征

- Policy (base LLM) 完全冻结
- 重点在 **memory architecture** 和 **retrieval 机制** 设计
- Agent 在任务执行后做反思, 把经验存入外部 memory

区别

- **MemRL**: 用 Q-value 驱动的两阶段 memory retrieval (语义 + 效用)
- **MUSE**: 分层 memory (strategic / procedural / tool), 更接近认知科学的 memory taxonomy

这一阶段的本质

这是 non-parametric self-evolving 路线的成熟形态——其实早在 2023 年 Reflexion / Voyager / Generative Agents 时代就有类似思路, MemRL / MUSE 是这条路线的系统化升级。

三、范式转折点 (2025/10) : EvolveR 引入 RL training

EvolveR 是这条路线上一个关键的拐点。

核心范式

在线交互 + 离线自蒸馏 + 在线 RL 更新 三者协同的闭环:

任务执行

- 检索 Experience Bank 中的 principle 辅助决策
- 生成轨迹
- GRPO 更新 policy (在线 RL)
- 离线把成功轨迹蒸馏为 Guiding Principle、失败轨迹蒸馏为 Cautionary Principle
- 周期性更新 Experience Bank、剪枝低质量 principle
- 进入下一轮

为什么是转折点

之前的工作只关心"如何提炼和管理 experience", EvolveR 同时优化 **model 利用 experience 的能力**。这标志着范式从 "non-parametric memory" 演化到 "hybrid (memory + parametric)"。

Output

训练结束后得到：一个高质量的 Experience Bank + 一个会主动利用它的 Policy Model。

四、EvolveR 框架的 component 级 optimization 浪潮

EvolveR 之后，一批工作在它的框架内做不同 component 的优化。本质上**框架没变**，只是优化了某个环节。

SkillRL (2026/02, UNC-Chapel Hill)

- **变化**：用 **GPT-o3** 作为 **teacher** 提炼 skill，构建 hierarchical SkillBank
- **训练**：GRPO 强化 policy 利用 skill 的能力
- **维护**：validation 阶段根据失败轨迹增删改 SkillBank
- **注意**：依赖外部 teacher，严格说不是完全的 self-evolving

D2Skill (2026/03, Institute of Automation)

- **变化**：提出 **任务级 skill + 步骤级 skill** 两种粒度
- 优化 skill 效用评分 (utility scoring + UCB exploration)
- **本质**：在 skill representation 的 granularity 上做扩展

RetroAgent (2026/03, Shanghai AI Lab)

- **变化**：扩展 reflection 的输出，让模型同时生成：
 - 子任务完成度 (potential score) → 用作 intrinsic reward 细化 GRPO 信号
 - Trajectory 是否成功的预测 → 用 REINFORCE 强化 reflection 能力本身
 - 可复用经验 → 进入 memory buffer
- **本质**：把 reflection 从单一动作拆成多个 sub-signals，分别用不同方式 leverage

小结：三者都是 EvolveR 框架的局部 optimization，没有突破闭环结构。

五、Divergent directions (2026/04 起)

到 2026 年中，社区开始出现几个明显不同的方向选择：

方向 A: Internalization 路线 —— SKILL0 (2026/04, Zhejiang University & Meituan)

- **核心问题**: skill 一直放外存够吗? 能不能内化进参数?
- **方法**: 基于 SkillRL 的 SkillBank, 通过 dynamic curriculum (逐步撤销 skill) + context rendering (压缩为 image) + 复合奖励, 把 skill 蒸馏进模型参数
- **意义**: 这是这个方向上唯一一个走 **parametric internalization** 的工作

方向 B: 分离 Curator 路线 —— SkilloS (2026/05, UIUC & Google)

- **核心问题**: 让同一个 policy 既执行任务又管理 skill 是否合理?
- **方法**: 把 agent 拆成 fixed **task executor** + trainable **skill curator**
- 用组合奖励 (task performance + skill content quality + library compactness 等) RL 优化 curator
- **意义**: 把 "experience curation" 提升为独立的 learning problem

方向 C: Unified Evolution 路线 —— Skill1 & Evolving-RL (2026/05)

- **核心问题**: skill 提炼、检索、使用三种能力应该被独立优化还是协同进化?
- **共同主张**: 用单一 task outcome 同时驱动三者的协同优化
- **Skill1 (USTC & Meituan)**: 从 task reward 中分解出"低频趋势"驱动 selection、"高频偏差"驱动 distillation
- **Evolving-RL (Xiaohongshu & PKU)**: 让同一个 policy 既做 extractor 又做 solver, 用 downstream task 的平均 reward 估计 skill quality, 反向优化 extraction

三个方向其实回答了三个不同的根本问题: experience 该放哪里 (A)、该谁来管 (B)、能力之间如何协同 (C)。

六、关于实验范式的观察

强烈的 convergence

几乎所有工作都收敛到同一个评估范式:

- **Benchmark**: 以 **ALFWorld** 和 **WebShop** 为主, 尤其 ALFWorld
- **协议**: training set 训练 → 得到优化的 model + skill bank → test set 评估
- **结果**: Skill1 和 Evolving-RL 在 ALFWorld 上平均分已经到 **96%+**

这反映什么

- Benchmark monoculture: 所有工作必须用同样的 benchmark 才能 comparable
- Score saturation: 方法 differentiation 在快速减弱
- 真实 deployment scenario (OOD、cross-task、long-term) 几乎没被测试

七、Adjacent / Alternative directions

以下方向跟主流路线相关但定位不同, 单独列出:

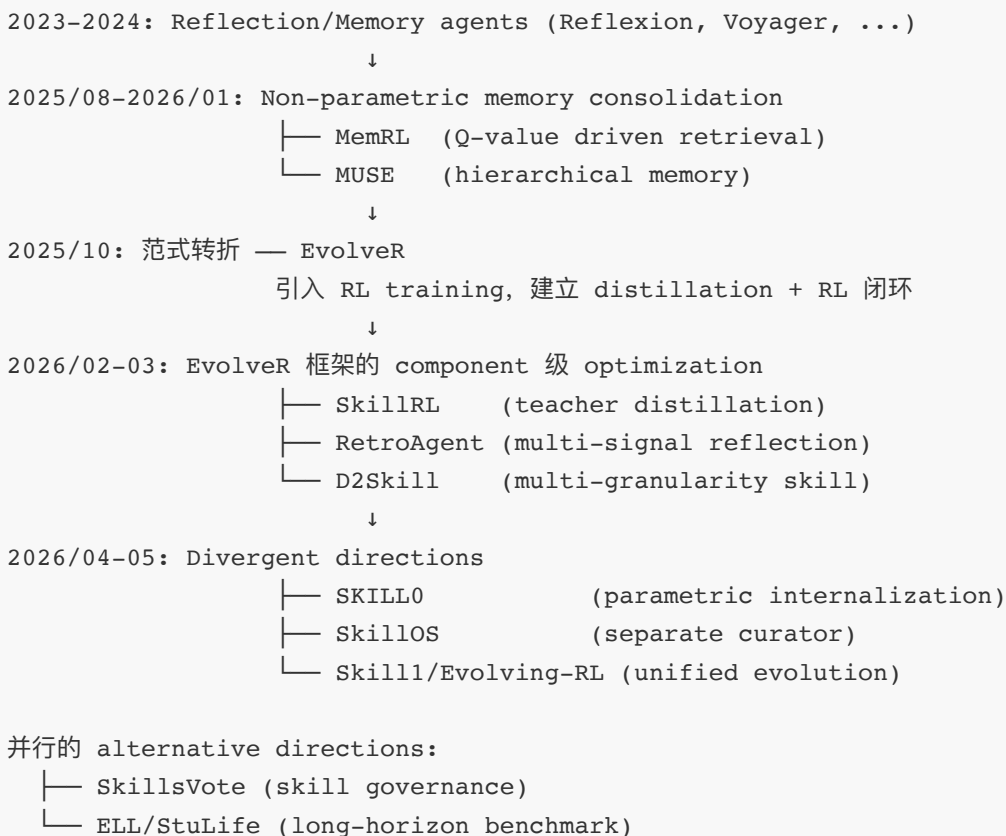
SkillsVote (2026/05, MemTensor)

- 定位偏产品/治理，提供高质量、可验证的 skill 库
- 重点在 skill governance: collection / recommendation / attribution / evolution lifecycle
- 引入了 **subtask-level attribution + evidence-gated evolution** 的机制
- 对"experience quality"这个问题做了非常具体的工程化处理

ELL & StuLife (2025/08, ECNU & Shanghai AI Lab)

- 提出 **Experience-driven Lifelong Learning (ELL)** 这个 framing
- 构建 **StuLife benchmark**: 模拟大学生一学期的 long-horizon、stateful 环境
- 价值在于提出了一个 alternative benchmark direction (不是 ALFWorld/WebShop 这种 closed-world toy)
- 但本身影响力还比较小

八、整体演化图谱



九、一句话总结

在过去 9 个月里，experience-driven self-evolving 这个方向经历了从 **non-parametric memory** 到 **hybrid (memory+RL)** 的范式转折，并迅速在 **EvolveR** 框架内分化出 **internalization**、**curation**、**unified evolution** 三个 **divergent** 方向。但所有工作都收敛到 **ALFWorld/WebShop** 这种 **closed-world toy benchmark** 上，**scores** 已经 **saturate**，方法的真实 **deployment** 价值仍未被验证。

Appendix: 主要工作速查表

Paper	Date	Affiliation	Citations	一句话
MemRL	2026/01	SJTU & MemTensor	35	Q-value 驱动的 non-parametric memory
MUSE	2025/10	CSU & Shanghai AI Lab	14	分层 memory (strategic/procedural/tool)
EvolveR	2025/10	ZJU & Shanghai AI Lab	44	范式转折点: distillation + RL 闭环
SkillRL	2026/02	UNC	57	Teacher (GPT-o3) 蒸馏 hierarchical skill
RetroAgent	2026/03	Shanghai AI Lab	6	Multi-signal reflection + intrinsic reward
D2Skill	2026/03	Inst. of Automation	2	Task-level + step-level skill 双粒度
SKILL0	2026/04	ZJU & Meituan	14	Internalization : 把 skill 蒸馏进参数
SkillOS	2026/05	UIUC & Google	1	分离 curator : 独立优化 skill manager
Skill1	2026/05	USTC & Meituan	1	Unified evolution
Evolving-RL	2026/05	Xiaohongshu Inc & PKU	0	Unified evolution

思考

- 1. 范式已经收敛，但不一定收敛对了
 - 几乎所有工作都落在 "在 training set 上 evolve → 在 test set 上评估" 的范式
 - 主流 benchmark 高度集中 (ALFWorld、WebShop)
 - Skill1 / Evolving-RL 在 ALFWorld 上已经 **96%+**
 - 这个 saturation 不代表问题被解决，更可能代表**evaluation 没 capture 真正的 capability**
- 2. 现有 "self-evolving" 本质上接近 fine-tuning
 - 有明确的 training phase 和 test phase
 - 除了被优化的model外，多了一个skill bank
 - **跟普通的 RL fine-tuning 在 evaluation 形式上 indistinguishable**
 - "Evolving" 这个词被使用，但缺乏 formal definition
- 3. 现有方法可能有overfit的风险
 - Skill0、Skill1都在目标数据集上做了很重的训练
 - 目标数据集的performance确实很高
 - 但是过度学习skill distillation、skill selection、skill internalization，可能会让模型的通用能力下降
- 4. Specialized training 可能并不必要
 - Claude / GPT-5 这种 frontier model 通过 prompting 可能就能做出 specialized model 的效果
 - Specialized training 在 OOD 上的 generalization 存疑
 - 没人 head-to-head 比较过
 - (不是说引入teacher model, 这违背了self-evolving。而是说，如果是更强的模型要self-evolving，可能不需要专门训练distill能力)

开会讨论的问题

- RL训练后的模型，利用其他skill的能力变强了吗？
- 把training label去掉，没有outcome能不能反思出有效的skill，只提供环境反馈